

梁悦 (Cassie Liang)

AI 应用研发工程师 (Agent / RAG / LLM)

13122900609 | liangyue3666@gmail.com | github.com/cassieliang6709 | liangyue.site



作品集

教育背景

Northeastern University | 人工智能硕士 · GPA 3.75/4.0 | 生成式 AI 课程研究生助教
上海财经大学 | 会计学学士 | 华为奖学金、人民奖学金

预计 2027.12
2023.06

专业技能

LLM / Agent: RAG、混合检索 (pgvector / BM25 / RRF)、MCP、结构化输出、MLX LoRA、评测与发布门槛
后端与数据: Python、FastAPI、PostgreSQL / pgvector、Redis、Docker、SQL、pytest、TypeScript
多模态与客户端: CLIP、ASR、VLM、TTS、React、Swift / SwiftUI、AVFoundation、Chrome Extension MV3

项目经历

MindBridge | 面向 Agent 的本地优先长期记忆引擎 · 独立开发

[GitHub](#) | [Demo](#)

Python · FastAPI · MCP · PostgreSQL / pgvector · Qwen2.5-3B · MLX LoRA · Redis

- 可靠摄取: 按 byte cursor 增量解析 Claude Code / Codex CLI 日志, 实测沉淀 3,067 轮 / 51 个会话。
- 记忆建模: 拆分 T1 原始轮次、T2 记忆卡与 T3 时序偏好, 以 cursor + source_key 保证幂等重建。
- 统一服务: MCP 与 HTTP 复用 MemoryService, 避免 Agent 工具与服务端写入、检索逻辑漂移。
- 本地微调: 以 198 条样本训练 MLX LoRA; 45 条日期隔离 holdout 首次结构通过率 86.7%, teacher 为 82.2%。

Vance | 可执行训练计划的 AI 健身搭子 · 独立开发

[GitHub](#) | [Demo](#)

SwiftUI · SwiftData · Cloudflare Workers / D1 · Kimi K2.6 · SSE · MiniMax TTS

- Agent 闭环: 以 tool_use / tool_result 调节重量、替换动作并生成计划, 结果回写模型继续生成。
- 计划约束: D1 种子库收录 1,324 条动作, 端侧精选 50 条结构化定义并按伤病、场地过滤。
- 服务架构: Worker 隔离 Kimi / MiniMax 密钥并统一 SSE 事件, iOS 端仅执行受控 action。
- 多模态交互: 串联语音输入、MiniMax TTS 与 Kimi 器械识别, 仅将高置信设备作为教练上下文。

CorpCheck | SEC 财报检索与确定性拒答系统 · 个人重构

[GitHub](#) | [Landing](#)

Python · FastAPI · PostgreSQL / pgvector · BM25 · RRF · MCP · FinanceBench

- 检索规模: 在 1,662 份 SEC filing / 469,874 个文本块上融合 pgvector、BM25 与 RRF。
- 版本治理: 在检索入口执行 section-aware 修正案裁剪, 防止旧 filing 片段进入排名与引用。
- 确定性拒答: LLM 调用前测量 top-1 / top-3 相似度与证据覆盖度, 低置信度直接返回拒答原因。
- 评测结果: FinanceBench 35 题中 top-10 无同 filing 证据的查询由 19 降至 4。

1Day | 本地优先的协作视频日记 iOS App · 独立开发 · Private Beta v1.1

[GitHub](#)

Swift · SwiftUI · AVFoundation · CloudKit · Sign in with Apple · XCTest

- 产品范围: 支持 1 天 / 7 天两种旅程与 2 / 5 / 10 秒三档短片, 避免素材无限增长。
- 端侧成片: 以 AVFoundation 归一视频方向、交替轨道与音频区间, 合成转场、字幕和 MP4。
- 协作一致性: 以 room + participant + slot 生成 CloudKit 确定性 ID, 重录更新原记录而非新增副本。
- 工程验证: 单人模式无需账号和后端; 当前 28 / 28 项 XCTest 通过, 覆盖状态、迁移与真实 MP4 导出。

工作经历

德勤 Deloitte | 审计助理

上海 | 2023.06—2024.12

Python · VBA · Excel Automation · SQL

- 自动映射: 开发 Python 试算表工具, 对齐 30,000+ 条总账记录, 单项目复核效率提升 60%。
- 规则复用: 将 20+ 项风控校验封装为可配置工作流, 覆盖 90% 常见错误并适配 10+ 家客户。

获奖项目 | VisoCode: 以 LangGraph 多 Agent 与 Docker 沙箱生成 Manim 教学动画, 获 AdventureX 2025 最佳技术奖。 [GitHub](#)

Becoming: 48 小时交付 AI 成长教练 MVP, 负责产品路径与前后端协作, 获创业森林二等奖。

其他项目 | Cassie Capture: 以 Content Script → Service Worker → Offscreen 流式管线分卷生成超长网页 PDF。 [GitHub](#)

TabSPACE: 本地优先的 Chrome 新标签页工作台, 支持标签分组、书签整理与 review-before-apply。 [GitHub](#)